

Analisis Komparatif Convolutional Neural Network dan Multi-Layer Perceptron untuk Klasifikasi Citra pada Dataset Fashion-MNIST

Regan Agam
Universitas Gadjah Mada

Abstract—Penelitian ini menyajikan analisis komparatif yang mendalam antara dua paradigma arsitektur jaringan saraf untuk tugas klasifikasi citra: Multi-Layer Perceptron (MLP) sebagai representasi Jaringan Saraf Tiruan (JST) konvensional, dan Convolutional Neural Network (CNN) sebagai arsitektur Deep Learning yang terspesialisasi. Menggunakan dataset benchmark Fashion-MNIST, yang terdiri dari 70.000 citra grayscale 28x28 piksel yang terbagi dalam 10 kelas artikel mode, kedua model diimplementasikan, dilatih, dan dievaluasi di bawah protokol eksperimental yang terkontrol. Hasil empiris menunjukkan keunggulan kinerja dari arsitektur yang terspesialisasi, meskipun tidak sebesar yang dilaporkan sebelumnya; model CNN mencapai akurasi uji sebesar 89.52%, sementara model MLP mencapai akurasi 87.96%. Analisis lebih lanjut terhadap metrik klasifikasi per kelas, dinamika pelatihan (selama 10 epoch), dan kompleksitas model secara kuantitatif memvalidasi bahwa keunggulan CNN berasal dari bias induktif arsitekturalnya. Kemampuan CNN untuk mengeksploitasi dan mempertahankan hierarki spasial fitur melalui lapisan konvolusional dan pooling, serta efisiensi yang dicapai melalui parameter sharing, terbukti menjadi faktor penentu dalam mengatasi keterbatasan fundamental MLP, yang kehilangan informasi spasial akibat proses perataan (flattening) input. Studi ini secara konklusif menunjukkan bahwa desain arsitektur yang selaras dengan struktur inheren data adalah prasyarat krusial untuk mencapai kinerja tinggi dalam domain visi komputer.

Index Terms—Deep Learning, Convolutional Neural Network, Multi-Layer Perceptron, Klasifikasi Citra, Fashion-MNIST, Jaringan Saraf Tiruan.

I. PENDAHULUAN

Dalam dekade terakhir, Kecerdasan Buatan (AI), Pembelajaran Mesin (ML), dan Pembelajaran Mendalam (Deep Learning) telah menjadi kekuatan transformatif di berbagai sektor teknologi. Ketiga bidang ini memiliki hubungan hierarkis, di mana Deep Learning merupakan bagian khusus dari Machine Learning, yang pada gilirannya adalah disiplin inti dalam AI. Salah satu tugas paling fundamental dan berpengaruh dalam domain visi komputer adalah klasifikasi citra, yaitu proses mengidentifikasi dan menetapkan label kategori ke sebuah citra digital [1]. Kemampuan ini menjadi dasar bagi aplikasi yang lebih kompleks, mulai dari sistem rekomendasi mode, manajemen inventaris ritel, hingga analisis tren visual.

Sejarah pengembangan jaringan saraf untuk tugas-tugas ini mencerminkan evolusi dari model yang bersifat umum menuju arsitektur yang sangat terspesialisasi. Arsitektur awal seperti Multi-Layer Perceptron (MLP) merupakan model yang kuat secara teoritis dan dapat dianggap sebagai *universal function*

approximator [1]. Namun, ketika dihadapkan pada data berdimensi tinggi dan terstruktur seperti citra, sifat konektivitas penuh (*fully connected*) dan ketidakmampuannya untuk memproses informasi spasial secara inheren menjadi penghalang signifikan. Hal ini memicu kebutuhan akan arsitektur baru yang dirancang khusus untuk data visual.

Tujuan dari penelitian ini adalah untuk melakukan perbandingan empiris dan teoretis yang ketat antara pendekatan MLP konvensional dan arsitektur Convolutional Neural Network (CNN) yang terspesialisasi. Perbandingan ini bukan sekadar evaluasi kinerja dua algoritma, melainkan sebuah demonstrasi dari pergeseran paradigma fundamental dalam desain model pembelajaran mesin. Pergeseran ini adalah dari model generik yang mencoba mempelajari segala sesuatu dari data mentah, ke model dengan *bias induktif* yang kuat. Bias induktif dalam CNN adalah asumsi-asumsi yang dibangun ke dalam arsitekturnya—seperti lokalitas spasial dan invarian translasi—yang secara fundamental selaras dengan sifat citra. Sebuah MLP, sebaliknya, tidak memiliki bias semacam itu; ia memperlakukan citra sebagai vektor piksel yang tidak terstruktur, memaksanya untuk mempelajari hubungan spasial paling dasar dari awal, sebuah tugas yang sangat tidak efisien dan rentan terhadap kegagalan generalisasi.

Kontribusi utama dari makalah ini adalah analisis komparatif yang terperinci, yang menghubungkan prinsip-prinsip arsitektur teoretis dengan metrik kinerja yang teramati, dinamika pelatihan, dan kompleksitas komputasi. Dengan mengimplementasikan, melatih, dan mengevaluasi kedua model pada dataset benchmark Fashion-MNIST, makalah ini akan secara empiris menunjukkan mengapa desain arsitektur yang terspesialisasi tidak hanya lebih baik, tetapi juga merupakan pendekatan yang secara fundamental lebih tepat untuk masalah klasifikasi citra.

II. LANDASAN TEORI ARSITEKTUR JARINGAN

Pemilihan arsitektur jaringan saraf adalah keputusan desain yang paling krusial dalam pemodelan Deep Learning. Bagian ini menguraikan fondasi teoretis dari dua arsitektur yang dibandingkan: MLP dan CNN.

A. Multi-Layer Perceptron (MLP): Pendekatan Konvensional

Multi-Layer Perceptron adalah kelas dari jaringan saraf tiruan *feedforward* yang terdiri dari setidaknya tiga lapisan node: lapisan input, satu atau lebih lapisan tersembunyi

(*hidden layers*), dan lapisan output [1]. Karakteristik yang mendefinisikan MLP adalah sifat konektivitas penuhnya, di mana setiap neuron dalam satu lapisan terhubung ke setiap neuron di lapisan berikutnya. Untuk memproses data citra, MLP mengharuskan input untuk "diratakan" (*flattened*) menjadi vektor satu dimensi. Sebuah citra dari dataset Fashion-MNIST dengan dimensi 28×28 piksel harus diubah menjadi vektor tunggal dengan panjang $28 \times 28 = 784$ fitur. Proses ini membawa beberapa keterbatasan:

- **Hilangnya informasi spasial:** Hubungan topologis antar piksel dihancurkan.
- **Inefisiensi parameter dan *overfitting*:** Sifat konektivitas penuh menyebabkan ledakan jumlah parameter, membuat model rentan terhadap *overfitting*.
- **Kurangnya invarian translasi:** Model harus mempelajari representasi terpisah untuk objek yang sama di lokasi yang berbeda.

B. Convolutional Neural Network (CNN): Arsitektur Terspesialisasi

Convolutional Neural Network (CNN) adalah arsitektur yang dirancang secara khusus untuk memproses data grid, seperti citra. Filosofi intinya, yang dipopulerkan oleh karya-karya awal seperti LeNet-5 [2], adalah bahwa model dapat belajar hierarki fitur spasial secara otomatis. Keberhasilan fenomenal dari arsitektur ini pada tugas klasifikasi skala besar divalidasi secara luas oleh model seperti AlexNet [3], yang secara signifikan mengungguli metode visi komputer tradisional. Komponen kunci yang mendasari keberhasilan ini meliputi:

- **Lapisan Konvolusional (*Convolutional Layer*):** Menggunakan filter atau *kernel* untuk melakukan konvolusi di seluruh input. Ini didasarkan pada **konektivitas lokal** dan **berbagi parameter** (*parameter sharing*), yang secara drastis mengurangi jumlah parameter dan memberikan **invarian translasi**.
- **Lapisan Pooling (*Pooling Layer*):** Melakukan *down-sampling* untuk mengurangi dimensi spasial, membuat representasi fitur lebih kuat terhadap pergeseran kecil.

Arsitektur CNN yang khas terdiri dari serangkaian lapisan konvolusional dan pooling sebagai *feature extractor*, diikuti oleh kepala klasifikasi (*classifier head*) yang terdiri dari lapisan *fully connected*.

III. PENGATURAN EKSPERIMENTAL

Untuk memastikan perbandingan yang adil, serangkaian protokol eksperimental yang terkontrol ditetapkan.

A. Dataset Fashion-MNIST dan Pra-pemrosesan

Eksperimen dalam penelitian ini menggunakan dataset publik Fashion-MNIST [4]. Dataset ini terdiri dari 70.000 citra grayscale 28×28 piksel dalam 10 kelas artikel mode. Dataset ini dibagi menjadi 60.000 citra pelatihan dan 10.000 citra pengujian. Kelas-kelas tersebut adalah: 'T-shirt/top', 'Trouser', 'Pullover', 'Dress', 'Coat', 'Sandal', 'Shirt', 'Sneaker', 'Bag', dan 'Ankle boot'. Visualisasi beberapa contoh dari dataset ditunjukkan pada Gambar 1.



Fig. 1. Contoh citra dari dataset Fashion-MNIST yang menunjukkan keragaman item dalam 10 kelas yang berbeda.

Langkah pra-pemrosesan yang dilakukan adalah:

- 1) **Normalisasi Nilai Piksel:** Nilai piksel dari rentang $[0, 255]$ diubah menjadi rentang $[0, 1]$ dengan membagi setiap nilai piksel dengan 255.0.
- 2) **Penanganan Label:** Label kategori digunakan dalam bentuk integer (0-9) karena penggunaan fungsi kerugian *sparse_categorical_crossentropy*.
- 3) **Penyesuaian Input CNN:** Untuk CNN, dimensi channel ditambahkan ke data citra (misalnya, 28×28 menjadi $28 \times 28 \times 1$).

B. Spesifikasi Model MLP

Model MLP yang diimplementasikan terdiri dari:

- **Lapisan Input:** Lapisan Flatten yang mengubah input 28×28 menjadi vektor 784 fitur.
- **Lapisan Tersembunyi:** Satu lapisan Dense dengan 128 neuron dan aktivasi ReLU.
- **Lapisan Output:** Lapisan Dense dengan 10 neuron (sesuai jumlah kelas) dan aktivasi softmax.

C. Spesifikasi Model CNN

Model CNN yang diimplementasikan terdiri dari:

- **Input Shape:** $28 \times 28 \times 1$.
- **Tulang Punggung Ekstraksi Fitur:**
 - **Blok Konvolusional 1:** Satu lapisan Conv2D (32 filter, kernel 3×3 , ReLU), diikuti oleh satu lapisan MaxPooling2D (2×2).
 - **Blok Konvolusional 2:** Satu lapisan Conv2D (64 filter, kernel 3×3 , ReLU), diikuti oleh satu lapisan MaxPooling2D (2×2).




Fig. 2. Diagram arsitektur model Multi-Layer Perceptron (MLP) yang digunakan dalam penelitian ini. Menunjukkan lapisan input yang diratakan, **satu** lapisan tersembunyi, dan lapisan output.

• Kepala Klasifikasi:

- Lapisan Flatten.
- Lapisan Dense (**128** neuron, ReLU).
- Lapisan Dense output (10 neuron, softmax).




Fig. 3. Diagram arsitektur model Convolutional Neural Network (CNN). Terdiri dari dua blok konvolusional (**masing-masing satu Conv2D**) untuk ekstraksi fitur, diikuti oleh kepala klasifikasi fully-connected (**dengan satu Dense layer**).

D. Protokol Pelatihan

Kedua model dilatih menggunakan protokol dan *hyperparameter* berikut:

- **Optimizer:** Adam (dengan *learning rate* default Keras, umumnya 0.001).
- **Fungsi Kerugian:** **Sparse** Categorical Cross-Entropy (karena label integer).
- **Metrik:** Akurasi.
- **Eksekusi Pelatihan:** Ukuran *batch* **32** (default Keras), selama **10 epoch**.
- **Validasi:** Menggunakan **20%** data pelatihan sebagai set validasi (*validation_split*=0.2).

IV. HASIL DAN ANALISIS KOMPARATIF

Bagian ini menyajikan hasil kuantitatif dari eksperimen dan memberikan analisis komparatif yang terperinci.

A. Kinerja Model Secara Keseluruhan

Evaluasi akhir pada 10.000 citra uji mengungkapkan perbedaan kinerja antara kedua model. Tabel I merangkum kinerja akhir dari kedua model.

TABLE I
PERBANDINGAN KINERJA MODEL PADA SET PENGUJIAN
FASHION-MNIST

Metrik	MLP	CNN
Akurasi Uji	87.96%	89.52%
Presisi Rata-rata Makro	0.88	0.90
Recall Rata-rata Makro	0.88	0.90
F1-Score Rata-rata Makro	0.88	0.89

Hasilnya menunjukkan: model CNN mengungguli model MLP di semua metrik evaluasi utama, meskipun perbedaannya tidak sebesar yang mungkin diharapkan atau dilaporkan dalam konfigurasi lain.

B. Dinamika Pelatihan dan Konvergensi

Analisis kurva pelatihan dan validasi memberikan wawasan penting tentang bagaimana setiap model belajar selama **10 epoch** dan kemampuannya untuk menggeneralisasi. Gambar 4 menyajikan perbandingan langsung dari kurva akurasi dan kerugian untuk kedua model.

Dari grafik perbandingan (**berdasarkan 10 epoch**):

- **Analisis MLP:** Kurva akurasi pelatihan (biru solid) cenderung naik lebih cepat daripada akurasi validasi (oranye solid), dan kerugian validasi (oranye solid) mulai menunjukkan tanda-tanda stagnasi atau peningkatan menjelang akhir 10 epoch, mengindikasikan potensi *overfitting* jika pelatihan dilanjutkan lebih lama.
- **Analisis CNN:** Kurva untuk model CNN (garis hijau dan merah putus-putus) menunjukkan kesenjangan yang lebih kecil antara metrik pelatihan dan validasi. Akurasi validasi terus meningkat dan kerugian validasi cenderung menurun lebih konsisten selama 10 epoch, menunjukkan kemampuan generalisasi yang lebih baik dalam periode pelatihan ini. CNN mencapai tingkat akurasi yang lebih




Fig. 4. Perbandingan kurva akurasi (kiri) dan kerugian (kanan) selama **10 epoch** pelatihan untuk model MLP dan CNN. Garis solid dan putus-putus masing-masing merepresentasikan metrik pelatihan dan validasi.

tinggi dan menunjukkan konvergensi yang lebih stabil dalam 10 epoch.

C. Efikasi Klasifikasi Per Kelas

Analisis kinerja pada tingkat per kelas dapat mengungkapkan kekuatan dan kelemahan spesifik dari setiap arsitektur.




Fig. 5. Matriks Kebingungan untuk Model MLP pada Set Pengujian.

Laporan klasifikasi untuk model MLP (Tabel II) menunjukkan kinerja yang bervariasi. Model ini tampaknya mengalami kesulitan pada kelas 'Shirt' (F1-score 0.69) dan 'Coat' (F1-score 0.77), seringkali bingung dengan kelas pakaian atasan lainnya. Hal ini juga dikonfirmasi oleh matriks kebingungan pada Gambar 5.

Sebaliknya, laporan klasifikasi untuk model CNN (Tabel III) dan matriks kebingungannya (Gambar 6) menunjukkan kinerja yang umumnya lebih tinggi dan lebih konsisten, meskipun




Fig. 6. Matriks Kebingungan untuk Model CNN pada Set Pengujian.

CNN juga menunjukkan F1-score terendah pada kelas 'Shirt' (0.70).

D. Kompleksitas dan Efisiensi Model

Perbandingan jumlah total parameter yang dapat dilatih memberikan wawasan tentang kompleksitas model (Tabel IV).

Berdasarkan arsitektur yang diimplementasikan dalam notebook, model **CNN memiliki jumlah parameter yang lebih banyak** daripada model MLP (**sekitar 2.2 kali lebih banyak**). Fakta bahwa CNN berkinerja lebih baik meskipun memiliki lebih banyak parameter dalam kasus ini menyoroti poin penting: bukan hanya jumlah parameter yang penting, tetapi bagaimana parameter tersebut digunakan dan seberapa cocok arsitektur dengan data. CNN menggunakan parameternya jauh lebih efisien untuk data citra dengan membagikannya di seluruh ruang (melalui kernel) dan memanfaatkan hierarki spasial,

TABLE II
LAPORAN KLASIFIKASI UNTUK MODEL MLP (BERDASARKAN
NOTEBOOK CELL 16)

Kelas	Precision	Recall	F1-Score
T-shirt/top	0.83	0.83	0.83
Trouser	1.00	0.96	0.98
Pullover	0.74	0.85	0.79
Dress	0.84	0.93	0.88
Coat	0.84	0.72	0.77
Sandal	0.96	0.97	0.97
Shirt	0.73	0.65	0.69
Sneaker	0.95	0.95	0.95
Bag	0.97	0.97	0.97
Ankle boot	0.96	0.96	0.96
accuracy			0.88
macro avg	0.88	0.88	0.88
weighted avg	0.88	0.88	0.88

TABLE III
LAPORAN KLASIFIKASI UNTUK MODEL CNN (BERDASARKAN
NOTEBOOK CELL 16)

Kelas	Precision	Recall	F1-Score
T-shirt/top	0.83	0.85	0.84
Trouser	0.99	0.97	0.98
Pullover	0.79	0.90	0.84
Dress	0.95	0.82	0.88
Coat	0.76	0.92	0.83
Sandal	0.96	0.99	0.98
Shirt	0.80	0.63	0.70
Sneaker	0.97	0.93	0.95
Bag	0.98	0.97	0.97
Ankle boot	0.96	0.97	0.96
accuracy			0.90
macro avg	0.90	0.90	0.89
weighted avg	0.90	0.90	0.89

TABLE IV
PERBANDINGAN KOMPLEKSITAS MODEL (BERDASARKAN NOTEBOOK)

Model	Total Parameter yang Dapat Dilatih
MLP	101,770
CNN	225,034

memungkinkannya untuk mempelajari representasi fitur yang kuat. MLP, meskipun lebih sedikit parameter, tidak dapat memanfaatkan struktur spasial ini.

E. Visualisasi Hasil Prediksi

Untuk memberikan perbandingan kualitatif, Gambar 7 menampilkan hasil prediksi dari kedua model pada 25 citra acak dari set pengujian. Terlihat bahwa CNN cenderung lebih konsisten dalam memberikan prediksi yang benar, meskipun kedua model membuat beberapa kesalahan pada kelas yang mirip secara visual.

V. DISKUSI

Hasil eksperimental secara tegas menunjukkan superioritas kuantitatif dari CNN atas MLP untuk tugas ini, meskipun dengan selisih yang lebih kecil (sekitar 1.56%) dibandingkan

laporan awal. Kesenjangan akurasi (**89.52%** vs **87.96%**) dapat diatribusikan pada perbedaan mendasar dalam cara kedua model memproses data spasial. MLP, dengan meratakan input, secara inheren menghancurkan struktur spasial yang krusial. Sebaliknya, arsitektur CNN dirancang secara eksplisit dengan bias induktif untuk data visual, mengeksplorasi dan mempertahankan informasi spasial ini.

Analisis kinerja per kelas (Tabel II dan III) semakin memperkuat argumen ini. Kesulitan kedua model dalam membedakan antara kelas-kelas yang secara visual serupa (misalnya, F1-score untuk 'Shirt' adalah **0.69** pada MLP vs **0.70** pada CNN) menyoroti tantangan dataset ini, namun CNN secara umum menunjukkan F1-score yang lebih baik atau setara di sebagian besar kelas lain. CNN unggul dalam hal ini dengan membangun hierarki fitur dari tepi sederhana hingga bagian objek yang lebih kompleks.

Perbandingan kompleksitas model (Tabel IV) menunjukkan bahwa dalam implementasi ini, **CNN memiliki parameter lebih banyak (225.034) daripada MLP (101.770)**. Kinerja CNN yang lebih baik *meskipun* memiliki lebih banyak parameter menegaskan bahwa efisiensi arsitektural dan kesesuaian dengan struktur data (melalui *parameter sharing* dan *local connectivity*) lebih penting daripada sekadar jumlah parameter total. Ini menggarisbawahi prinsip penting dalam Deep Learning bahwa bias induktif yang dirancang dengan baik lebih berharga daripada kapasitas model mentah atau jumlah parameter semata.

VI. KESIMPULAN

Studi ini melakukan analisis komparatif yang sistematis antara arsitektur MLP konvensional dan CNN modern pada dataset Fashion-MNIST berdasarkan implementasi kode yang disediakan. Hasil eksperimen secara konsisten menunjukkan bahwa CNN mengungguli MLP pada metrik evaluasi. Temuan utama dari penelitian ini adalah:

- 1) **Kinerja Unggul CNN:** CNN mencapai akurasi uji sebesar **89.52%**, sementara MLP mencapai **87.96%**.
- 2) **Penyebab Fundamental:** Kinerja superior CNN adalah konsekuensi langsung dari desain arsitekturalnya yang terspesialisasi, yang mampu mempertahankan dan mengeksplorasi informasi spasial melalui lapisan konvolusional dan pooling.
- 3) **Efisiensi Arsitektur vs. Jumlah Parameter:** Kinerja superior tidak selalu berkorelasi dengan jumlah parameter yang lebih sedikit. Dalam kasus ini, CNN memiliki **lebih banyak parameter** tetapi berkinerja lebih baik karena penggunaan parameternya yang efisien melalui *parameter sharing* dan kemampuannya menangkap fitur spasial.

Secara keseluruhan, penelitian ini menegaskan kembali bahwa untuk tugas klasifikasi citra, arsitektur seperti CNN yang dirancang dengan pemahaman tentang sifat data secara fundamental lebih unggul daripada pendekatan generik seperti MLP standar.



Fig. 7. Visualisasi hasil prediksi pada 25 citra acak dari set pengujian. Setiap citra menampilkan label asli, prediksi model MLP, dan prediksi model CNN. Ini memberikan perbandingan kualitatif kinerja kedua model.

REFERENCES

- [1] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [2] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [3] A. Krizhevsky, I. Sutsver, and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems (NIPS)*, 2012, pp. 1097–1105.
- [4] H. Xiao, K. Rasul, and R. Vollgraf, "Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms," *arXiv preprint arXiv:1708.07747*, 2017.